

[1.] ELI 5

Imagina que estás jugando un videojuego de shooters como Fortnite, pero el objetivo es encontrar y capturar una bandera que está en el punto más alto del mapa. En este mapa hay mucha niebla y es muy difícil ver a lo lejos, pero tenemos algunas herramientas para guiarnos. Decides que la estrategia más inteligente es ir subiendo tantos los montes que nos encontremos y esperamos que sean los más altos. Para llegar más rápido usamos un jetpack para brincar entre puntos en vez de caminar. Entonces, ¿cómo sabemos montes? No podemos ver muy lejos pero podemos ver el punto en el que estamos parados bastante bien. Con poner sobre el suelo algo como una pelota o un nivelador podemos ver la inclinación: hacia dónde es y qué tan inclinado está. Entonces podemos hacer eso y decidimos lo lógico: tiene sentido brincar en "sentido contrario" a la dirección en la que rodó la pelota. Entonces usamos una regla simple:

1. Si no se movió la Pelota no hay inclinación y ent. No hay hacia dónde subir. No tenemos por qué movernos. Esperamos haber llegado al punto más alto.
2. Si hay inclinación, brincamos con el jetpack en dirección "hacia arriba" del monte.

Peró ¿Qué tan lejos brincamos?

Si brincamos de lado legos podemos brincar la cima! Entonces queremos brincar tan lejos como se pueda sin pasarnos para no desperdiciar gasolina del jetpack. Para ayudarnos, lanzamos piedritas en la dirección en la que vamos a saltar (idea cinda de backtracking. Nota para examen ne pare te niño). Avanzamos piedritas más y más lejos cada vez hasta que ya no vuelvan a bajar rodando. La última distancia a la que tiramos es a la que vamos a brincar.

Una vez habiendo brincado volvemos a chequear la inclinación. Seguimos hasta que no haya inclinación y estemos en piso plano. Cuando hayamos llegado a piso plano habremos llegado a la cima que buscábamos, o al menos llegamos a una cima. No sabemos si es la más alta y es difícil saber si lo es.

4.2] DEMO (CH 3 - pg. 42 Convergence rate of steepest descent)

f cuadrática convexa $f(x) = \frac{1}{2} x^T Q x - b^T x$

P.D. el minimizador de una dim. sobre la línea

$$x_k + \alpha p_k \text{ es } \alpha_k = - \frac{\nabla f_k^T p_k}{p_k^T Q p_k}$$

Queremos minimizar sobre $x_k + \alpha p_k$. Ent. basta
con encontrar los puntos estacionarios

$$\frac{\partial}{\partial \alpha} (f(x_k + \alpha p_k)) = 0.$$

$$\text{Tenemos } f(x) = \frac{1}{2} x^T Q x - b^T x$$

$$= \frac{1}{2} (x_k + \alpha p_k)^T Q (x_k + \alpha p_k) - b^T (x_k + \alpha p_k)$$

$$= \frac{1}{2} x_k^T Q x_k + \frac{1}{2} x_k^T Q \alpha p_k + \frac{1}{2} \alpha p_k^T Q x_k + \frac{1}{2} \alpha^2 p_k^T Q p_k - b^T x_k - \alpha b^T p_k$$

$$= \frac{1}{2} x_k^T Q x_k + \alpha x_k^T Q p_k + \frac{1}{2} \alpha^2 p_k^T Q p_k - b^T x_k - \alpha b^T p_k$$

$$\therefore \frac{\partial}{\partial \alpha} (f(x_k + \alpha p_k)) = x_k^T Q p_k + \alpha p_k^T Q p_k - b^T p_k$$

$$= p_k^T (x_k^T Q + \alpha p_k^T Q - b^T) p_k$$

$$= \underbrace{(\alpha p_k^T Q + x_k^T Q - b^T)}_{(H)} p_k \quad \begin{array}{l} Q \text{ simétrica} \\ \text{por } f \text{ convexa} \end{array}$$

El libro señala que $\nabla f(x) = Qx - b \Rightarrow \nabla f(x^T) = Qx^T - b^T = x_k^T Q - b^T$

$$(\alpha p_k^T Q + \nabla f(x_k^T)) p_k = 0$$

$$\Leftrightarrow \alpha p_k^T Q = - \nabla f(x_k^T) \Rightarrow \alpha = - \frac{\nabla f(x_k^T)}{p_k^T Q}$$

No puedo dividir entre cosas que no se si son
números reales (i.e. $p_k^T Q$)

$$\begin{aligned}\frac{\partial}{\partial \alpha} H(x_k + \alpha p_k) &= x_k^T Q p_k + x_k^T Q p_k - b^T p_k \\ &= \alpha p_k^T Q p_k + (x_k^T Q - b^T) p_k\end{aligned}$$

Como Q simétrica porque f convexa

$$x_k^T Q - b^T = Q x_k - b^T = \nabla f(x_k) \text{ (lo dice el libro).}$$

$$\therefore \frac{\partial}{\partial \alpha} H(x_k + \alpha p_k) = \alpha p_k^T Q p_k + \nabla f(x_k)^T p_k = 0$$

$$\Rightarrow \alpha p_k^T Q p_k = - \nabla f(x_k)^T p_k$$

$p_k^T Q p_k$ está bien definido y es escalar dado

$$\alpha = - \frac{\nabla f(x_k)^T p_k}{p_k^T Q p_k} \quad \text{q.e.d.} \quad \square$$