

## Teoría

## 1.1 Gradiente Conjugado

a) La demostración procede por contradicción

Supongamos que  $p_1, \dots, p_k$  son linealmente dependientes. Entonces existe  $p_k \in \mathbb{R}^n$  tal que

$$p_k = \sum_{i \neq k} \alpha_i p_i \quad (p_k \text{ es combinación lineal de los } p_i)$$

con  $\alpha_i \in \mathbb{R}$  y  $p_i \in \mathbb{R}^n$ . Entonces, para alguna  $j \in \{1, \dots, k\}$  tenemos que

$$\Rightarrow p_j^T A p_k = p_j^T A \left( \sum_{i \neq k} \alpha_i p_i \right) = \sum_{i \neq k} (p_j^T A \alpha_i p_i) = \sum_{i \neq k} \alpha_i (p_j^T A p_i)$$

$$= \alpha_j p_j^T A p_j$$

$$(p_i^T A p_j = 0, \forall i \neq j)$$

Así pues, por un lado (\*)  $0 = p_j^T A p_k$  por hipótesis pero probamos por otro lado que  $p_j^T A p_k = \alpha_j p_j^T A p_j \neq 0$  !

De este modo tenemos contradicción.

Así,  $\{p_1, \dots, p_k\}$  es linealmente independiente.b) Sea  $A \in \mathbb{R}^{n \times n}$  simétrica definida positiva y  $x^*$  la solución del problema. Consideremos  $p_0, \dots, p_{n-1}$  vectores tales que

$$p_i^T A p_j = 0, \quad \forall i \neq j$$

Por el anterior inciso vemos que  $\text{span}(\{p_0, \dots, p_{n-1}\}) = \mathbb{R}^n$

Consideremos a  $x_0 \in \mathbb{R}^n$  y resulta que

$$x^* - x_0 = \sum_{i=0}^{n-1} \sigma_i p_i \quad \text{con } \sigma_i \in \mathbb{R}, p_i \in \mathbb{R}^n$$

donde

$$\sigma_k = \frac{p_k^T A (x^* - x_0)}{p_k^T A p_k}$$

Minimización de  $\sigma_k$

$$x^* = x_0 + \sigma_0 p_0 + \dots + \sigma_{n-1} p_{n-1}$$

$$\Rightarrow x^* - x_0 = \sigma_0 p_0 + \dots + \sigma_{n-1} p_{n-1}$$

$$p_k^T A (x^* - x_0) = p_k^T A \left( \sum_{i=0}^{n-1} \sigma_i p_i \right) = \sigma_k p_k^T A p_k$$

$$\Rightarrow \sigma_k = \frac{p_k^T A (x^* - x_0)}{p_k^T A p_k} \quad \left( \begin{array}{l} \text{análogo} \\ \text{a inciso (1)} \\ \text{BA} p_i = 0, \forall i \neq j \end{array} \right)$$

Ahora bien,  $x^* - x_0 = \sum_{i=0}^{n-1} \sigma_i p_i$  ;  $\sigma_k = \frac{p_k^T A (x^* - x_0)}{p_k^T A p_k}$

Dado que el algoritmo genera  $x_k$  de la forma

$$x_k = x_0 + \alpha_0 p_0 + \alpha_1 p_1 + \dots + \alpha_{k-1} p_{k-1}$$

resulta que

$$x_k - x_0 = \alpha_0 p_0 + \alpha_1 p_1 + \dots + \alpha_{k-1} p_{k-1}$$

$$\Rightarrow p_k^T A (x_k - x_0) = p_k^T A \left( \sum_{i=0}^{k-1} \alpha_i p_i \right) = 0 \quad \left( \begin{array}{l} p_i^T A p_j = 0 \\ \forall i \neq j \end{array} \right)$$

Por lo tanto,

$$p_k^T A (x^* - x_0) = p_k^T A (x^* - x_k) = p_k^T (b - A x_k) = -p_k^T r_k$$

De este modo como  $\sigma_k = \frac{p_k^T A (x^* - x_k)}{p_k^T A p_k}$


y como el paso es  $x_{k+1} = x_k + \alpha_k p_k$

con  $\alpha_k = \frac{-r_k^T p_k}{p_k^T A p_k}$

resulta que  $\sigma_k = \alpha_k$

Así se haya el óptimo en  $n$  pasos o menos.

Este resultado es válido para cualquier problema. Primero si las coordenadas del problema tiene elipses paralelos es fácil de ver pues se recorre junto a los elipses. (Figura 1)



(Figura 1)

Si los elipses son tan rotados como en la Figura siguiente (Figura 2) tarda más de  $n$  pasos. Lo único que nos queremos es cambiar de coordenadas con otra base canónica y se cumple como en la última Figura (3)




Figura (2)




Figura 3



## 1.2) BFGS

•) P.D.  $B_{k+1} H_{k+1} = I = H_{k+1} B_{k+1}$

Primero recordemos las definiciones y propiedades

$$H_{k+1} = (I - \rho_k s_k y_k^T) H_k (I - \rho_k y_k s_k^T) + \rho_k s_k s_k^T$$

$$B_{k+1} = B_k - \frac{B_k s_k s_k^T B_k}{s_k^T B_k s_k} + \frac{y_k y_k^T}{y_k^T s_k}$$

con  $\rho_k = \frac{1}{y_k^T s_k}$ ,  $B_{k+1} s_k = y_k$ ,  $H_{k+1} y_k = s_k$ ,  $H_k = B_k^{-1}$

$$B_{k+1} H_{k+1} = B_{k+1} \left\{ (I - \rho_k s_k y_k^T) H_k (I - \rho_k y_k s_k^T) + \rho_k s_k s_k^T \right\}$$

De (II) obtenemos que

$$\begin{aligned} B_{k+1} \rho_k y_k y_k^T &= \left\{ B_k - \frac{B_k s_k s_k^T B_k}{s_k^T B_k s_k} + \frac{y_k y_k^T}{y_k^T s_k} \right\} \frac{1}{y_k^T s_k} s_k s_k^T \\ &= \frac{B_k s_k s_k^T}{y_k^T s_k} - \frac{B_k s_k (s_k^T B_k s_k) s_k^T}{(s_k^T B_k s_k) y_k^T s_k} + \frac{y_k (y_k^T s_k) s_k^T}{(y_k^T s_k) y_k^T s_k} \\ &= \frac{B_k s_k s_k^T}{y_k^T s_k} - \frac{B_k s_k s_k^T}{y_k^T s_k} + \frac{y_k s_k^T}{y_k^T s_k} = \frac{y_k s_k^T}{y_k^T s_k} \quad \dots (*) \end{aligned}$$

De (I) obtenemos que

$$\begin{aligned} B_{k+1} (I - \rho_k s_k y_k^T) H_k (I - \rho_k y_k s_k^T) &= \left[ \left( B_k - \frac{B_k s_k s_k^T B_k}{s_k^T B_k s_k} + \frac{y_k y_k^T}{y_k^T s_k} \right) (H_k - \rho_k s_k y_k^T H_k) \right] (I - \rho_k y_k s_k^T) \\ &= \left( I - \frac{B_k s_k y_k^T}{s_k^T B_k s_k} + \frac{y_k y_k^T H_k}{y_k^T s_k} - \frac{B_k s_k y_k^T H_k}{y_k^T s_k} + \frac{B_k s_k (s_k^T B_k s_k) y_k^T H_k}{(s_k^T B_k s_k) y_k^T s_k} \right. \\ &\quad \left. - \frac{y_k y_k^T s_k y_k^T H_k}{y_k^T s_k y_k^T s_k} \right) \left( I - \frac{y_k s_k^T}{y_k^T s_k} \right) \end{aligned}$$

$$= \left( I - \frac{B_k S_k S_k^T}{S_k^T B_k S_k} + \frac{Y_k Y_k^T H_k}{Y_k^T S_k} - \frac{B_k S_k Y_k^T H_k}{Y_k^T S_k} + \frac{B_k S_k Y_k^T H_k}{Y_k^T S_k} - \frac{Y_k Y_k^T S_k S_k^T H_k}{Y_k^T S_k Y_k^T S_k} \right) \left( I - \frac{Y_k S_k^T}{Y_k^T S_k} \right)$$

$$= \left( I - \frac{B_k S_k S_k^T}{S_k^T B_k S_k} + \frac{S_k S_k^T H_k}{Y_k^T S_k} - \frac{S_k (Y_k^T S_k) S_k^T H_k}{Y_k^T S_k (Y_k^T S_k)} \right) \left( I - \frac{Y_k S_k^T}{Y_k^T S_k} \right)$$

$$= \left( I - \frac{B_k S_k S_k^T}{S_k^T B_k S_k} + \frac{S_k S_k^T H_k}{Y_k^T S_k} - \frac{S_k S_k^T H_k}{Y_k^T S_k} \right) \left( I - \frac{Y_k S_k^T}{Y_k^T S_k} \right)$$

$$= \left( I - \frac{B_k S_k S_k^T}{S_k^T B_k S_k} \right) \left( I - \frac{Y_k S_k^T}{Y_k^T S_k} \right)$$

$$= I - \frac{S_k Y_k^T}{Y_k^T S_k} - \frac{B_k S_k S_k^T}{S_k^T B_k S_k} + \frac{B_k S_k (Y_k^T S_k) S_k^T}{S_k^T B_k S_k (Y_k^T S_k)}$$

$$= I - \frac{S_k Y_k^T}{Y_k^T S_k} - \frac{B_k S_k S_k^T}{S_k^T B_k S_k} + \frac{B_k S_k S_k^T}{S_k^T B_k S_k}$$

$$= I - \frac{S_k Y_k^T}{Y_k^T S_k} \quad (\neq)$$

Finalmente sumando (\*) y (\*\*) )

$$H_{k+1} B_{k+1} = I - \frac{S_k Y_k^T}{Y_k^T S_k} + \frac{S_k Y_k^T}{Y_k^T S_k} = I$$

Por lo tanto  $H_{k+1} = B_{k+1}^{-1}$